

Datasets para el detector de fin de turno

Deep research reducido a la decisión útil para el ejercicio técnico de HappyRobot. Revisión 2: mismos datasets, otro uso de los datos.

Decisión

Usaría [Pipecat Smart Turn v3.2](#) para train/dev, re-cortado a nivel de pausa (prefix mining), y reservaría [LiveKit EoT Bench](#) como test externo en el harness oficial, EN y ES con el mismo checkpoint. Si el acceso es inmediato, añadiría [Krisp Turn-Taking Test](#) como segundo test.

Por qué

- Smart Turn ya etiqueta exactamente EOT vs HOLD, conserva prosodia y tiene suficiente audio humano en inglés.
- Pero entrena ‘¿clip completo?’ y se despliega ‘¿esta pausa es HOLD?’: ~94% acc en clips, 35.2% false cutoffs en EoT Bench. Sus pausas internas son los negativos que faltan; prefix mining los extrae sin datos nuevos.
- LiveKit evalúa las decisiones reales en cada pausa de conversaciones humano–agente y entrega el contexto del agente (messages); no comparte la fuente de entrenamiento.

Shortlist

Dataset	Papel	Calidad útil	Fricción / caveat
Smart Turn v3.2	Train/dev (minado)	Target exacto; EN mayoritariamente humano; ~3 decisiones/clip tras minar	41.4 GB; sin transcript, speaker_id ni contexto
LiveKit EoT Bench	Test principal EN + ES	Pausas reales, audio + words + messages	Solo 400 turnos por idioma (±3 pt)
Krisp test v1	Segundo test	Labels manuales; 30 speakers	Gated; test-only
otoSpeech-104h	Aux dual-channel	Train de TurnBench; 2 canales, word timings, roles; abierto	Humano-humano; stretch
Challenge numérico	Eval de dominio	MC/load IDs/rates/teléfonos dictados con pausas; con pregunta del agente	Sintético (Kokoro); solo eval
AppTek Call-Center	Stress EN + contexto	128.6 h, 14 acentos, transcripts manuales	Sin labels EOT/HOLD

Qué cambia respecto a la revisión 1

Prefix mining como palanca central; EoT Bench en ruta crítica; un checkpoint multilingüe para EN y ES; campo agent_text en todas las filas; otoSpeech-104h y challenge set añadidos; baseline textual sobre partial ASR eliminado. El por qué: output/CHANGES_RATIONALE.md; el código: src/eot/.

Prefix mining: la palanca de datos que no cuesta nada

EoT Bench y producción puntúan cada silencio ≥ 100 ms de un turno: el último es EOT, los anteriores HOLD. Smart Turn etiqueta clips enteros. Cada clip ya contiene los HOLD que faltan: sus pausas internas. `src/eot/prefix_mining.py` (CLI `eot-mine`) los extrae.

Región del clip	Muestra generada	Label	Target fvad ('habla en 0.24/0.64/1.2/2.0 s')
Pausa interna ≥ 200 ms con habla después	prefijo cortado a 0.2 / 0.4 / 0.6 s dentro de la pausa	HOLD (0)	1 para horizontes $\geq$ time_to_onset real
Pausa final de clip completo	prefijo cortado a la misma rejilla	EOT (1)	todo 0
Clip incompleto que termina a medias	clip entero + 200 ms de cola	HOLD (0)	enmascarado (duración censurada)

- Rendimiento esperado: ~2 pausas internas por clip $\rightarrow$ 20k clips $\approx$ 60–80k decisiones, ratio HOLD:EOT $\approx$ 3:1 (como el benchmark: 850:400).
- Los prefijos del mismo clip nunca cruzan train/dev: split por fuente (campo dataset) con fallback a clip_id.
- El corte cae siempre dentro de silencio detectado; nunca mid-word. Detector energético offline: auditar histograma de pausas y escuchar ~50 cortes.
- Los targets fvad son gratis (timestamps) y dan al modelo un target graduado tipo Next-Turn / DualTurn future-VAD; en inferencia sirven de trigger especulativo.

Augmentación PSTN en training, no solo en eval

telephony_augment: band-limit 8 kHz, mu-law G.711, jitter de ganancia, ruido a 12–35 dB SNR, packet drops 20–80 ms; aplicado al 30% de las muestras. Los carriers llaman desde la cabina por PSTN; la prosodia fina que un modelo aprende en audio limpio no sobrevive al canal. Slices clean y telephony se reportan por separado.

Campo agent_text

Cada fila lleva la última frase del agente (vacía si no existe). Fuentes con contexto: LiveKit (messages), SpokenWOZ, AppTek, challenge set. Smart Turn: vacío, por eso la rama de contexto entrena con dropout 0.3 y se evalúa con/sin contexto sobre las mismas filas. No hace falta transcript del usuario en ningún punto: la rama es zero-latency y no depende del ASR.

Qué no usaría como core

LEMAS, LibriSpeech, Common Voice o el corpus de un TTS: un final de archivo no equivale a un final conversacional. Pueden ayudar como augmentación, no como evidencia principal.

La combinación recomendada

1 · Smart Turn v3.2 — entrenamiento

[Dataset train](#) · [Test](#) · [Guía de etiquetado](#)

Idioma	Humano	Sintético	Total	HOLD	EOT
EN	43,617 · 66.3%	22,185 · 33.7%	65,802	33,359	32,443
ES	3,986 · 24.9%	12,047 · 75.1%	16,033	8,076	7,957

Auditoría sobre las 83 shards Parquet de train, sin decodificar audio.

- Schema directo: audio + endpoint_bool; balance casi 50:50.
- La guía exige finales incompletos naturales —fillers, conectores o prosodia suspendida— y prohíbe cortar mid-word.
- spoken_text es nulo y no hay contexto del agente: el baseline textual se elimina y la rama de contexto se entrena con dropout.
- No hay speaker_id ni documentación suficiente para probar que el split es speaker-disjoint. Separar por campo dataset y comprobar similitud de voz.
- La receta pública (train.py) es fine-tune completo de whisper-tiny multilingüe sobre 270k clips: cualquier run propia debe usar el mismo optimizador para que la diferencia sea atribuible a los datos.

2 · LiveKit — evaluación externa

[Dataset](#) · [Harness y metodología](#)

Idioma	Turnos	Decisiones de pausa	EOT	HOLD	Duración media
EN	400	1,250	400	850	12.60 s
ES	400	1,236	400	836	12.94 s

- Cada pausa interna es HOLD; la pausa final es EOT. Audio 16 kHz + word timestamps + messages cuando existe: el adapter propio (src/eot/eotbench_adapter.py) los usa; el de LiveKit v1 no.
- Mantener EN intacto para test. Congelar el punto de operación en dev antes de abrir el resultado; bootstrap por turno (±3 pt).
- Referencias públicas: EN v1 9.9% / Smart Turn 35.2% / VAD 55.6%; ES v1 ~16% / Smart Turn ~39% / VAD ~55% FC @300 ms.

Manifest mínimo para la entrega

Split	Fuente	Volumen
train	Smart Turn EN ~20k clips, 50:50, 70–80% humano → eot-mine	~60–80k decisiones
dev	Smart Turn EN separado por fuente (prefijos no cruzan)	~15% de las decisiones
test A	Smart Turn test EN (clips; cautela con independencia)	2k–5k
test B	LiveKit EN en el harness oficial	1,250 pausas
bonus	LiveKit ES con el mismo checkpoint (+ Smart Turn ES en train si hay tiempo)	1,236 pausas
dominio	eot-challenge: dictado numérico con pregunta del agente	200 turnos, ~400 HOLD
aux (stretch)	otoSpeech-104h canal usuario minado / dual-channel	104 h

Alternativas y respuesta sobre Kokoro

Alternativas que sí añaden señal

Dataset	Qué aporta	Por qué no es core
Krisp Turn-Taking Test v1	2,730 clips; 4 h; 55 episodios; 30 speakers; 976 shift / 1,754 hold; labels manuales	Gated y test-only
otoSpeech-104h	104 h dual-channel, word timings y roles; train público de TurnBench (test oculto)	Humano-humano; pretraining dual/oráculo, no core
DualTurn / OtoSpeech	287 h, 1,120 sesiones, dos canales; EOT/HOLD/backchannel por frame	Mimi features, ~25 GB y modelo 0.5B
AppTek Call-Center	873 conversaciones agente–cliente, 156 speakers, 14 acentos, 16 dominios; trae la pregunta del agente	Hay que derivar pausas y labels con eot-mine
SpokenWOZ	249 h, 203k turnos, 5.7k diálogos task-oriented; audio + contexto del agente en mirror HF	Sin EOT/HOLD directo; útil para la rama de contexto
Open Yap sample	Conversación natural, overlap/backchannels, tracks separados	Solo 8.9 h y 8 speakers en HF
Scicom Semantic-VAD	7.69M filas; 490k EN y ES; word timing	Labels posicionales por forced alignment; ~153 GB

Fuentes: [otoSpeech-104h](#) · [DualTurn](#) · [AppTek](#) · [SpokenWOZ](#) · [Open Yap](#) · [Scicom](#)

¿Es público el dataset de Kokoro?

No, no el corpus completo

El [model card de Kokoro-82M](#) declara ‘unos pocos cientos de horas’, datos permisivos/no protegidos y síntesis de proveedores cerrados. Solo identifica dos piezas: <1 h Koniwa y <11 h SIWIS. No publica manifest, prompts, splits ni corpus completo.

Modelos recientes con más apertura

Modelo	Disclosure	Utilidad real aquí
LEMAS-TTS (2026)	LEMAS-Dataset público: >150k h, 10 idiomas; EN 25.3k h, ES 21.2k h	TTS/align; no turn labels; enorme
Parler-TTS Mini	Receta exacta con LibriTTS-R + MLS	Lectura/audiolibro; augment
MagpieTTS 2026	Lista fuentes y 54,305 h, pero incluye interno/propietario	Sintetizador EN/ES; no corpus reproducible

Uso correcto de TTS

Kokoro + un segundo motor solo para hard cases: números, emails, nombres deletreados, fillers y autocorrecciones. Máximo 10–20% del train; voces/generadores fuera del test; medir real-only vs synthetic-only. El challenge set de dominio (eot-challenge --tts kokoro: MC/DOT, load IDs, rates, teléfonos con pausas de 0.3–1.2 s y la pregunta del agente) es solo evaluación.

Protocolo de calidad y fuentes

Checks mínimos antes de entrenar

- Normalizar a 16 kHz mono; rechazar silencio, corrupción y clipping severo; ventana útil ≤ 8 s.
- Deduplicar waveform y transcript; auditar duración, trailing silence, fuente, label y human/synthetic.
- Tras eot-mine: histograma de pausas, ratio HOLD:EOT ($\sim 3:1$), % de clips sin pausa interna y escucha de ~ 50 cortes HOLD.
- Escuchar 25 ejemplos por celda crítica; el challenge set numérico y el slice PSTN sintético son celdas obligatorias.
- Etiquetar de forma unificada: 1 = EOT/respond now; 0 = HOLD/keep listening. Nunca usar futuro posterior a la pausa (los targets fvad usan el futuro solo como label, nunca como input).
- Medir por idioma, fuente y clean/telephony: false cutoff @300/600, delay @5/10%, calibración y p50/p95/p99 de inferencia, con bootstrap por turno.
- Baselines en el mismo harness: VAD timer; Smart Turn v3.2; propio sobre clips enteros vs minado; $\pm$ contexto; $\pm$ fvad; encoder congelado.

La frase para defender la elección

'Entrené sobre las mismas decisiones que toma el detector en producción, con la receta completa; mi evidencia principal está en pausas humanas de LiveKit que el modelo nunca vio, en el harness público. La síntesis aporta cobertura, no valida calidad.'

Caveats que conviene declarar

- Prefix mining depende de un detector de silencio energético offline; un clip ruidoso puede cortar en habla de baja energía. Mitigación: min pause 200 ms, auditoría de escucha, Silero opcional.
- Smart Turn: no transcript, no speaker_id, sin contexto del agente y split por hablante no verificable desde el schema.
- LiveKit: muestra pública pequeña (± 3 pt); el español tiene menos historia contextual que el inglés.
- El bonus español se evalúa con el checkpoint EN multilingüe; si se añade Smart Turn ES, 75.1% es sintético.
- El objetivo $<25\%$ FC @300 ms es una hipótesis razonada, no un resultado medido.
- Krisp/OtoSpeech raw son gated; el acceso puede ser más limitante que la licencia para esta entrega.

Fuentes primarias principales

1. [Pipecat Smart Turn train y repositorio](#).
2. [LiveKit EoT Bench dataset y metodología](#).
3. [Krisp Turn-Taking Test v1](#).
4. [otoSpeech-104h](#) · [TurnBench](#) · [DualTurn/OtoSpeech](#) y [paper](#).
5. [AppTek Call-Center](#) · [SpokenWOZ paper](#) · [Open Yap](#).
6. [Kokoro-82M](#) · [LEMAS-TTS](#) · [Parler-TTS](#) · [MaggieTTS](#).

Nota

El PDF aportado se usó solo para fijar los requisitos del ejercicio. La licencia se mantuvo como consideración secundaria, siguiendo la indicación del usuario; calidad, adecuación del label y validez del test guiaron la selección.