

Modelos para detección de fin de turno

Deep research para el ejercicio MLE de HappyRobot: estado del arte, tradeoffs y una decisión que cabe en 9 horas. Revisión 2: receta alineada con la evaluación.

Decisión

Entrenaría la receta Smart Turn alineada con la evaluación: openai/whisper-tiny (multilingüe), fine-tune completo, attention pooling y cabeza EOT/HOLD sobre muestras a nivel de pausa (prefix mining) extraídas de los clips públicos. Dos extensiones ablatables: contexto del agente y cabezas de future-speech. VAD activa el score; threshold, delay y timeout forman la política. Evaluación en el harness de EoT Bench, EN y ES con el mismo checkpoint.

La posición honesta

- LiveKit v1 es el techo publicado en EoT Bench (9.9% FC @300 ms); no es entrenable ni reproducible como receta.
- Smart Turn v3.2 tiene ~94% de accuracy en clips y 35.2% de false cutoffs: la brecha es train/eval mismatch, no capacidad.
- El adapter de LiveKit v1 envía solo audio; el harness permite messages. El contexto del agente es una palanca no explotada.
- Kyutai STT, X2-Turn, Parakeet EOU, Flux muestran que el destino productivo, si controlas el STT, es compartir encoder y estado.
- Moshi, PersonaPlex y GPT-Live eliminan el detector discreto; son el horizonte full-duplex, no el entregable.

35.2 → <25% objetivo FC @300 ms	9.9% LiveKit v1 FC @300 ms	~60–80k decisiones tras prefix mining	16 ms p95 c=1 medido, M4 CPU
--	--------------------------------------	---	--

Qué cambia respecto a la revisión 1

Fine-tune completo en vez de encoder congelado; prefix mining como palanca de datos; contexto del agente y cabezas fvad; EoT Bench en ruta crítica; un solo backbone multilingüe; sección de dominio HappyRobot. El por qué de cada cambio está en output/CHANGES_RATIONALE.md; la implementación, en src/eot/.

DualTurn se analiza después como resultado auto-reportado sobre el mismo harness; no se inserta en el ranking oficial de LiveKit.

1 • Formular bien el problema

Un VAD pregunta si hay voz. Un detector EOT pregunta si, en esta pausa, el usuario ha cedido el turno o piensa continuar. El producto completo distingue EOT/shift, HOLD, backchannel e interrupción.

Evento	Qué significa	Error si se confunde
EOT / shift	El usuario terminó y abre el floor	Dead air si esperamos demasiado
HOLD	Duda, lista, reparación o pausa interna	El agente habla encima
Backchannel	'mhm', 'vale' sin pedir el turno	El agente se corta a sí mismo
Interrupción	El usuario quiere tomar el floor	El agente no cede

Tres relojes que no se deben mezclar

Reloj	Definición	Decisión asociada
Model compute	Preprocess + forward + API	¿Cumple p95 <100 ms?
Endpointing delay	Último frame hablado → commit	¿Cuánto dead air compramos?
End-to-first-audio	EOT real → audio del agente	¿Cómo se siente el sistema?

Ejemplo

Un modelo puede tardar 12 ms y aun responder a los 612 ms porque la política espera 600 ms de silencio. EoT Bench llama latencia al dead air, no al forward. [\[S1\]](#)

Métrica principal

- Curva de Pareto false-cutoff vs endpointing delay, no accuracy aislada.
- Puntos: false cutoffs @300/@600 ms y delay @5%/@10% de cutoff; bootstrap por turno (±3 pt con 1,250 decisiones).
- También: turn interrupted rate, timeout/miss rate y detect rate.
- Split agrupado por fuente/voz; prefijos del mismo clip nunca cruzan train/dev.
- AUPRC, Brier/ECE y macro-F1 quedan como diagnósticos del score.

La brecha que explica todo

Smart Turn entrena y evalúa clips completos (~94% acc) pero se despliega en pausas (35.2% FC). EoT Bench puntúa cada silencio ≥100 ms de un turno real: el último es EOT y los anteriores HOLD. Entrenar sobre esa misma distribución es la hipótesis central del entregable.

2 · Mapa de familias

Familia	Ve	Ventaja	Límite	Ejemplos
VAD + timer	voz/silencio	barato	pausa != fin	Silero, TEN
Texto	transcript + historia	gramática/intención	STT lag; sin prosodia	TurnGPT, LK text, TEN
Audio por turno	waveform actual (+ contexto agente)	prosodia; CPU	sin canal 2	Smart Turn, Krisp TP, este trabajo
Fusión	audio + semántica	qué + cómo	compute/complexidad	LiveKit v1, UltraVAD, FastTurn
Dual streaming	ambos speakers	BC/overlap/futuro	duty cycle alto	VAP, DualTurn
Dentro del STT	hidden states/tokens	coste marginal bajo	vendor/ASR coupling	Flux, Parakeet, Kyutai, X2-Turn
Full duplex S2S	audio in/out continuo	dinámica completa	GPU + poco control	Moshi, PersonaPlex

La dimensión operativa oculta

Patrón	Cuándo computa	Implicación de escala
Pause-triggered	Una o pocas veces por pausa	bursts cortos; buen uso de CPU
Continuous	Cada 10-240 ms por llamada activa	capacidad ligada a concurrencia
ASR-integrated	Dentro del stream que ya existe	mejor si el STT ya es propio
Remote API	Proveedor mantiene estado	RTT, coste y lock-in

Decisión por contexto

- Si hay 9 horas y se exige entrenar: audio por turno con datos alineados a pausas y el contexto que ya es gratis.
- Si el STT ya es propio (HappyRobot afina su ASR a jerga logística): cabeza EOT compartida, patrón Parakeet/X2-Turn/Kyutai.
- Si se necesita barge-in/backchannel: dual streaming, pretraining en otoSpeech-104h.
- Si se compra una pila cerrada completa: evaluar servicio integrado, no el clasificador aislado.
- Si se rediseña todo el producto: estudiar full-duplex S2S, con safety gates observables.

Principio de selección

El mejor modelo no es el que tiene más parámetros; es el que observa la señal necesaria antes del deadline, se entrena sobre la misma decisión que tomará en producción y cuya política puede calibrarse con el coste real de interrumpir.


3 · Las dos referencias más cercanas

Pipecat Smart Turn v3.2

Campo	Detalle	Lectura
Input	16 kHz mono; último turno; max 8 s; left pad	simple y portable
Modelo	Whisper Tiny encoder (multilingüe) + attention pool + MLP; ~8M	cabe en CPU
Receta real	fine-tune completo; lr 5e-5; 4 ep; batch 384; warmup 20%; cosine; 270k clips	nada congelado
Artefacto	8 MB INT8 / 32 MB FP32	ONNX listo
Trigger	VAD; re-run si el usuario retoma	bajo duty cycle
Contexto	sin turnos previos ni audio del agente	pierde pragmática
EoT Bench	35.2% FC @300; 14.8% @600 (EN); ~39% @300 (ES)	baseline, no SOTA

Leer train.py cambia la estrategia: la receta pública ya es agresiva. Una run con encoder congelado y media época sobre 15k clips queda por debajo de v3.2 por construcción. Se copian interfaz, arquitectura, exportación y optimizador; se cambian los datos. Los pesos publicados se mantienen como baseline congelado en el mismo harness. [\[S2/S3\]](#)

LiveKit Audio Turn Detector v1



- v1 completo: LiveKit Inference; mejor calidad; arquitectura/datos/tamaño no publicados.
- v1-mini: misma idea, podado/cuantizado y CPU; 27.8% FC @300: pruning pierde frontier.
- Requiere VAD y min silence >=250 ms; 14 idiomas con thresholds por idioma. [\[S4/S5\]](#)

Lo que el adapter revela


livekit_turn_detector_adapter.py abre un websocket, envía PCM y pide p(eot); no envía messages. El README del harness dice que cada adapter recibe audio, messages y el transcript parcial (words + transcript_lag). El líder del benchmark no usa el contexto que el benchmark permite; un modelo pequeño condicionado en la última frase del agente es una palanca legítima. [\[S35\]](#)

Trampa de nombres: el repositorio HF livekit/turn-detector es el modelo de texto deprecado sobre Qwen2.5-0.5B, no Audio v1. [\[S6\]](#)

4 · EoT Bench: el frontier relevante

Conversaciones reales humano-agente, 14 idiomas. Cada silencio ≥ 100 ms es una decisión causal: el último es EOT y los anteriores HOLD. Se barre threshold + action delay + timeout. [\[S1\]](#)

False cutoffs @ 300 ms - EoT Bench EN



Modelo	FC @300	FC @600	Delay @5%	Detect @5%	Delay @10%
LiveKit v1	9.9%	4.5%	543 ms	91.0%	295 ms
Soniox	—	5.5%	647 ms	86.5%	512 ms
Deepgram Flux	12.9%	9.9%	1,151 ms	50.7%	548 ms
UltraVAD	27.7%	11.9%	899 ms	95.5%	663 ms
LiveKit v1-mini	27.8%	12.1%	1,070 ms	71.5%	698 ms
Smart Turn v3.2	35.2%	14.8%	1,051 ms	84.8%	739 ms
OpenAI / AssemblyAI / Cartesia	~45–50%	~23–30%	—	—	—
VAD baseline	55.6%	21.7%	1,600 ms	—	1,000 ms

Selección del reporte oficial; las filas de proveedores cerrados se leen de la figura y son aproximadas. DualTurn queda fuera de la tabla oficial; su card reporta 21.8/10.2% y 1,115/610 ms sobre el mismo harness, con datos privados. Español: v1 ~16%, Smart Turn ~39%, VAD ~55% @300 ms.

Objetivos declarados antes de correr

Meta	Cómo	Realismo en 9 h
<25% FC @300 (EN)	prefix mining + fine-tune completo	hipótesis razonada; sería el mejor audio-only pequeño de CPU
<15%	+ contexto del agente o fusión	posible si el contexto aporta en este dominio
9.9% (v1)	datos privados + fusión completa	no alcanzable con datos públicos; decirlo

No vender como ranking universal

El editor del benchmark también publica el ganador, solo hay validation público y el dominio es task-oriented. Aun así, datos, harness y predicciones abiertas lo hacen la evidencia más útil para HappyRobot; por eso pasa a la ruta crítica.

5 · Frontier local y papers que cambian la receta

DualTurn Endpointing

- Mimi congelado a 12.5 Hz + readout causal ~1.5M; EOT, VAD y future-VAD cada 80 ms.
- Mono funciona como fallback con canal de agente silencioso; el valor completo es dual-channel.
- El ONNX streaming declara ~52 ms por tick de 80 ms en CPU: baja latencia, alto duty cycle.
- Training: Switchboard + OtoSpeech + gran corpus privado de llamadas de agentes. [\[S7/S8\]](#)

Voice Activity Projection

- Predice actividad conjunta futura de dos speakers durante 2 s; deriva SHIFT/HOLD, onset y backchannels.
- Aprende sin labels EOT explícitos y los estudios de perturbación confirman uso de prosodia.
- En TurnBench: recall 0.845, FPR 0.055, mediana 368 ms; fuerte en dinámica natural. [\[S9/S10\]](#)

UltraVAD

- Fusiona historia textual + audio y predice un token EOT; 26 idiomas; 65-110 ms en A6000.
- Inconsistencia pública: tarjeta dice Llama-8B y HF muestra 0.7B params.
- Gana en su set contextual TTS, no en Orpheus single-turn; 27.7% FC @300 en EoT Bench. [\[S12\]](#)

SpeculativeETD / OpenETD

- ACL 2026: GRU barato detecta non-speaking en edge; Wav2Vec2 servidor resuelve Gap vs Pause.
- Gran idea de cascada para volumen; más red/operación y encoder mucho mayor que Whisper Tiny. [\[S13\]](#)

Ideas de training que sí caben (y ya están implementadas)

Paper / idea	Qué propone	Cómo entra en src/eot
Next-Turn 2026	predecir tiempo hasta siguiente onset	cabezas fvad multi-horizonte 0.24/0.64/1.2/2.0 s
DualTurn FVAD	future-VAD como target auxiliar	targets gratis desde prefix mining; loss enmascarada si censurado
Udupa 2025	label delay + codec features	grid 0.2/0.4/0.6 s dentro de la pausa; mu-law augment
EoT Bench	decisiones por pausa, no por clip	prefix_mining.py: HOLD internos + EOT final

Next-Turn reporta +25.9 puntos de endpoint accuracy <=320 ms en corpus privado chino; Udupa reporta -42.7% cutoff relativo a mediana 160 ms. Son evidencias de dirección, no números transferibles. [\[S14\]](#) · [\[S15\]](#)

WavLM/wav2vec2 son el contrafactual SSL natural para prosodia: TurnBench reporta WavLM Large Anchor 0.800/0.054 y ESPnet Turntaking 0.826/0.078. Un encoder swap es stretch si ya está cacheado. [\[S11\]](#)

6 · Endpointing dentro del STT

Tres sistemas abiertos responden hoy a ‘¿puede hacerlo el transcriptor?’

Sistema	Arquitectura	Output EOT	Latencia / coste	Abierto
Parakeet Realtime EOU 120M	FastConformer-RNNT cache-aware	token <EOU>	stream 80–160 ms; EOU p50 160 ms; CUDA	pesos; eval con TTS + 3 s
Kyutai STT 1B en/fr	delayed streams modeling	semantic VAD: P(fin) con retardo adaptativo	GPU Rust server; 64 streams L40S	pesos + receta
X2-Turn 4B	Voxtral-Mini Realtime + cabeza frame-sync	6 estados cada 80 ms, anclados al token ASR	τ = 480 ms como knob	código + checkpoint

Kyutai en TurnBench: recall 0.773, FPR 0.059, mediana 1,007 ms; Unmute lo usa con umbral 0.6 para pausa y <0.4 para interrupción. X2-Turn se evalúa en EasyTurn ZH/EN. FastTurn y SoulX-Duplug (2026) siguen la misma línea con CTC streaming + LLM pequeño. La comunidad converge en ‘estado compartido con el ASR’. [\[S17\]](#) · [\[S31\]](#) · [\[S32\]](#) · [\[S33\]](#)

Arquitectura recomendada si HappyRobot controla el ASR

Encoder streaming compartido + cabeza endpoint separada sobre features acústicas y estados lingüísticos. Loss multitarea; no dejar que errores de EOT degraden WER (Chang et al., RNN-T). HappyRobot ya afina su ASR a jerga logística: el detector Whisper separado es el experimento de 9 h y el fallback portable. [\[S18\]](#)

Sistemas de producto

Sistema	Semántica	Control	Tradeoff
Deepgram Flux	start/update/eager/end/resume	EOT/eager threshold + timeout	rollback; 50–70% más LLM calls en eager
AssemblyAI	semantic confidence + acoustic fallback	min/max silence	~49% FC @300 en EoT Bench
Soniox	token <end> integrado	sensibilidad + max delay	2º en EoT Bench @5/10%; early finalization vs WER
Cartesia Ink 2	eager_end/resume/end	3 thresholds + timeout	~50% FC @300 en EoT Bench
OpenAI Realtime	server_vad o semantic_vad	threshold/silence o eagerness	sin P(EOT); ~45% FC @300

Fuentes: [Flux](#) · [AssemblyAI](#) · [Soniox](#) · [Cartesia](#) · [OpenAI](#)

Krisp: Turn Prediction v3 (~9M, multilingüe) estima EOT en silencio; Interruption Prediction v1 (~6M, EN) separa backchannel de barge-in durante overlap. CPU, 40 ms frames; pesos cerrados, benchmark owner-reported. [\[S24\]](#)

7 · Texto y full-duplex: dónde encajan

Texto no es gratis, salvo el del agente

Modelo	Qué aporta	Por qué no es core
TurnGPT	completitud pragmática con contexto	sin prosodia; transcript lag
LiveKit text	Qwen 0.5B destilado, 14 idiomas	deprecado; hasta 6 turnos/128 tokens
TEN	finished/unfinished/wait	Qwen2.5-7B; EN/ZH; eval propia
Easy Turn	Whisper-M + Qwen 0.5B; 4 estados	dos modelos; set/latencia propios

El transcript del usuario llega tarde y depende del ASR. La última frase del agente se conoce antes de que el usuario hable, no cuesta latencia y predice la forma de la respuesta: ‘¿cuál es tu MC number?’ → dígitos con pausas; ‘¿algo más?’ → respuesta corta. En esta entrega, el modelo es audio-first y condiciona en el texto del agente (hash n-gram → embedding → gate); el baseline de texto sobre partial ASR de la revisión 1 se elimina: el harness ya cubre esa pregunta con UltraVAD y v1.

Full-duplex speech-to-speech

Sistema	Diseño	Ventaja	Límite para HappyRobot
Moshi	Mimi + temporal transformer 7B; streams user/agent	overlap sin turn boundary; 160/200 ms	L4/GPU; sustituye toda la pila
PersonaPlex	Moshi + role prompt + voice prompt	rol/voz y dinámica natural	modelo 7B; operación y control
GPT-Live	continuous audio fast path + async delegation	sin detector en ruta de audio	cerrado; sin eval EOT reproducible

Fuentes: [Moshi](#) · [PersonaPlex](#) · [GPT-Live](#)

Un dato contraintuitivo

TurnBench mide a Moshi con recall EOT 0.233, FPR 0.044 y mediana 702 ms. Una experiencia full-duplex natural no implica ser un buen clasificador EOT extraíble.

Anticipar en vez de esperar

Endpoint Anticipation 2026 predice el final hasta 2.56 s antes y lanza LLM/TTS especulativamente; en Unmute, 505 ms menos latencia media a cambio de 28.4% más compute redundante. Las cabezas fvad de este trabajo (‘¿habla en 2 s?’) son exactamente el trigger que ese esquema necesita; el objetivo futuro es una superficie de tres costes: cutoff, latencia y trabajo cancelado. [\[S29\]](#)

8 · TurnBench y la selección final

TurnBench evalúa 30 h, 154 diálogos dual-channel, 106 actores, seis dominios y tres anotadores. El test es oculto y puntúa EOT e interrupción por separado. Su train set público, otoSpeech-104h, es el único corpus abierto dual-channel con timestamps por palabra y roles. [\[S11\]](#) · [\[S34\]](#)

Modelo	Recall	FPR	Mediana
Tavus Sparrow-2*	0.930	0.084	615 ms
Gemini 3.1 Flash Live*	0.856	0.064	754 ms
Nunchi v1 dual*	0.851	0.040	610 ms
VAP	0.845	0.055	368 ms
ESPnet Turntaking	0.826	0.078	646 ms
WavLM Large Anchor	0.800	0.054	738 ms
Mimi Endpointer	0.782	0.078	645 ms
Kyutai semantic VAD	0.773	0.059	1,007 ms
Smart Turn v3	0.752	0.047	1,017 ms
OpenAI semantic VAD	0.303	0.018	793 ms
Moshi	0.233	0.044	702 ms

* External/closed submission. No mezclar con EoT Bench: humano-humano, dual-channel, eventos y métrica distintos. Los humanos empiezan transiciones suaves una mediana de 151 ms antes del final anotado.


Matriz de decisión

Opción	Calidad	<100 ms	Train 9 h	Veredicto
Whisper Tiny full-FT + prefix mining (+ctx, +fvad)	objetivo <25% FC	10–14 ms/forward medidos	sí: min GPU / ~1 h M4	ELEGIR
Smart Turn v3.2 weights	35.2%	sí	—	baseline congelado
LiveKit v1	max en EoT Bench	no publicado	no	north star
LiveKit v1-mini	27.8%	probable	sin receta	stretch baseline
DualTurn endpoint	21.8% (self-reported)	por tick	no práctico	roadmap
VAP	alta dinámica	posible	riesgo alto	roadmap
Parakeet / X2-Turn / Kyutai	alta si ya ASR	stream 80–480	no	preferible si ya es STT
Moshi/PersonaPlex	full duplex	GPU	no	horizonte

Resultado

Elegir la opción pequeña no es conservadurismo si se entrena con la receta completa y sobre la decisión correcta. El estado del arte aparece como baselines, ablations y roadmap; el objetivo declarado es el mejor audio-only pequeño de CPU en el harness público.

9 · Arquitectura y plan de 9 horas



Modelo (src/eot/model.py)

- Backbone único openai/whisper-tiny multilingüe, el de Smart Turn v3; EN y ES con el mismo checkpoint. Tabla posicional recortada a 400, no reiniciada.
- Attention pooling + MLP 384 → 256 → 64 → 1: receta Smart Turn. Fine-tune completo, lr 5e-5, cosine, warmup 20%, wd 0.01, 3 épocas. --freeze-encoder solo como ablación.
- Prefix mining: cada pausa interna ≥200 ms → HOLD cortado a 0.2/0.4/0.6 s con time-to-onset conocido; pausa final del clip completo → EOT; clip incompleto entero → HOLD censurado. 20k clips ≈ 60–80k decisiones.
- Contexto del agente: hash uni/bigramas → embedding 128 → gate sobre el vector pooled; dropout de contexto 0.3; sin tokenizer; exportable a ONNX.
- Cabezas fvad: ‘¿habla en 0.24/0.64/1.2/2.0 s?’; BCE enmascarada; peso 0.5. Sirven de trigger especulativo.
- PSTN: band-limit 8 kHz, mu-law G.711, ganancia, ruido 12–35 dB, packet drops 20–80 ms al 30% de muestras; slices clean/PSTN separados.

Política causal (src/eot/policy.py)

- Score a 200 ms de nonspeech; si HOLD, seguir; hard timeout 2.5-3.0 s. Endpointer con generation id descarta inferencias stale.
- Barrido threshold × action delay × timeout sobre las predicciones del harness (eot-sweep); Pareto y puntos FC@300/600, delay@5/10%; pre-registrar un punto en dev.

Agenda revisada

Hora	Salida
pre	clonar eot-bench; cachear EoT Bench EN+ES y ~20k clips EN; smoke test de src/eot; fijar hardware
0–0.75	audit/dedup/split por fuente; eot-mine; distribución de pausas; baseline silence-only
0.75–2.5	eot-train full-FT 3 ep (prefix + fvad); en paralelo Smart Turn y VAD en eot-bench
2.5–3.25	run --use-context o ablación congelada; eot-export + parity del primer checkpoint
3.25–4.25	adapter propio en eot-bench EN; eot-sweep; congelar punto; bootstrap por turno
4.25–5.25	FastAPI + Docker; eot-loadtest c=1/4/8 con audio real; cold vs warm
5.25–6	ES en eot-bench con el mismo checkpoint; slices PSTN y challenge numérico
6–7	tabla comparativa, Pareto, ablaciones
7–8	monitoring, dominio, discusión
8–9	README, vídeo y buffer

Qué salió de la ruta crítica para pagar esto

El baseline de texto sobre partial ASR (45 min, dependencia externa, pregunta ya respondida por el harness) y la run ES separada (mismo checkpoint multilingüe). El código listo antes del reloj es lo que hace viable EoT Bench dentro de las 9 h.

10 · Evidencia, serving y producción

Ablations, todas en el mismo harness y política

#	Experimento	Pregunta
1	VAD timers (p_eot=1 en el sweep)	¿cuánto aporta ML sobre silencio?
2	Smart Turn v3.2 congelado (adapter oficial)	¿mejora la receta publicada?
3	Whisper full-FT sobre clips enteros (subset)	¿cuánto cuesta el subset?
4	Whisper full-FT sobre prefix mining	¿cuánto vale alinear la decisión? (hipótesis central)
5	(4) + contexto del agente vía messages	¿qué añade la semántica gratis?
6	(4) + fvad; (4) + ambos	¿ayuda el target graduado?
7	Encoder congelado	¿basta la representación genérica? (esperado: no)
8	FP32 vs INT8 + parity	¿calidad/calibración cambian?
9	Slices: clean/PSTN, humano/sintético, silence-only, challenge numérico, ES	¿codec/shortcut/dominio explican el score?

Serving (src/eot/serve.py, load_test.py, Dockerfile)

- ONNX Runtime FP32 (32 MB), session caliente, warm-up por el camino completo (feature extractor incluido: sin él, el primer request costaba 640 ms).
- Body PCM16/WAV binario; respuesta con p_eot, p_fvad, decisión, sha del modelo y timings decode/features/inference/total.
- Threads fijos, semáforo de inflight con 503 al saturar, 409 si el deadline del caller expiró (resultado stale).

10–14 ms forward CPU FP32	16 ms p95 total c=1	34 / 67 ms p95 total c=4 / c=8	144 req/s throughput c=8
------------------------------	------------------------	-----------------------------------	-----------------------------

Medido en Apple M4, 2 intra-op threads, 8 s de audio, pesos de smoke test (el coste no depende de los pesos). Repetir en la máquina objetivo nombrada.

Monitorización a 1M llamadas/mes

Señal	Proxy / métrica
Corte	usuario retoma 0–2 s tras empezar el agente; cancelación inmediata; 'sorry, go ahead'
Dead air	último speech -> primer PCM del agente
Fallback	timeouts, VAD disagreements, 503/409 del servicio
Drift	score/calibración por idioma, cliente, campaña, SNR, codec, tipo de pregunta del agente
Negocio	re-preguntas, duración de llamada, captura correcta de MC/rate/teléfono al primer intento

Experimento natural gratis

Si el agente esperó y el usuario siguió: la pausa era HOLD. Si el agente habló y el usuario no protestó en 2 s: era EOT. Solo el EOT seguido de retoma inmediato es ambiguo. 1M llamadas/mes son >10M decisiones etiquetadas en el dominio exacto; un pequeño % de tráfico con timeout largo corrige el sesgo de solo observar los HOLD que la política permitió.

11 · Dominio HappyRobot y cómo batir el SOTA de verdad

El dominio no es un slice: condiciona el modelo

Rasgo	Consecuencia para EOT	Qué hace este diseño
PSTN desde cabina	banda 300–3,400 Hz, G.711, ruido de motor; prosodia fina se pierde	telephony_augment en training, no solo en eval
Datos dictados	MC/DOT, load IDs, teléfonos, rates: dígitos agrupados con pausas 0.5–1.2 s	contexto del agente + challenge set (eot-challenge)
Acentos / L2 / ES	gran proporción de carriers no nativos	backbone multilingüe; ES en EoT Bench
Llamadas largas	8 s pierden el estado de la tarea	el contexto del agente recupera parte
Coste asimétrico	cortar al carrier al dar un precio es caro; el dead air, menos	punto de operación por tipo de pregunta

En la entrega

- Mejor modelo audio-only pequeño de CPU en EoT Bench (objetivo <25% FC @300 ms vs 35.2% Smart Turn y 27.8% v1-mini), con intervalos declarados.
- Primer resultado con contexto del agente en un modelo pequeño sobre este harness.

Con datos de HappyRobot, ordenado por retorno/riesgo

#	Apuesta	Por qué funciona
1	Labels de pausa desde el experimento natural	>10M decisiones/mes en el dominio exacto, audio PSTN real; nadie público tiene esto
2	Cabeza EOT sobre el ASR propio (Parakeet/X2-Turn/Kyutai)	el estado streaming ya se paga; la cabeza cuesta ~1 ms y ve texto + acústica
3	Dual-channel	el audio del agente ya está en el proceso; pretraining otoSpeech-104h; backchannel e interrupción
4	Anticipación especulativa	fvad ya predice ‘no habla en 2 s’; lanzar LLM/TTS y cancelar en resume compra 300–500 ms
5	Destilar un oráculo no causal	el mismo modelo con 2 s de futuro etiqueta soft labels para el causal; barato y global

Lo que no haría

Entrenar un LLM de fusión tipo UltraVAD para CPU, ni full-duplex S2S para este producto en 2026: ambos requieren GPU por llamada y pierden control sobre la política. Tampoco reentrenar automáticamente sobre proxies ruidosos.

12 · Guion de discusión y fuentes

Respuestas de 20 segundos

- Audio vs texto: audio conserva prosodia y no espera al STT; texto gana en gramática y datos estructurados. La parte de texto que es gratis y causal es la del agente: se usa como condicionamiento. El transcript del usuario, al ASR compartido del roadmap.
- Vs VAD: VAD propone el momento; el modelo decide si la pausa es HOLD o EOT.
- 94% acc y 35% FC: train/eval mismatch entre clips y pausas; prefix mining lo alinea sin datos nuevos.
- Whisper/Parakeet: encoder streaming compartido + cabeza EOT. Parakeet EOU, X2-Turn y Kyutai STT lo demuestran, los dos últimos abiertos.
- Límites: prefix mining depende de un detector de silencio offline; sin speaker IDs; max 8 s; dependencia del VAD; sin canal del agente ni backchannels; el contexto solo ayuda si el agente pregunta cosas predecibles.
- Roadmap: labels del experimento natural -> cabeza sobre ASR propio -> dual-channel -> especulación/rollback -> full-duplex.

Fuentes esenciales

1. [LiveKit EoT Bench](#) · [adapter v1](#) · [audio v1](#) · [docs](#)
2. [Pipecat Smart Turn](#) · [train.py](#) · [model card](#)
3. [DualTurn paper](#) · [Endpointing model](#) · [otoSpeech-104h](#)
4. [VAP](#) · [prosody study](#) · [TurnBench](#)
5. [UltraVAD](#) · [SpeculativeETD](#) · [Next-Turn](#) · [label delay](#)
6. [Parakeet EOU](#) · [Kyutai STT](#) · [X2-Turn](#) · [FastTurn](#) · [SoulX-Duplug](#) · [RNN-T turn head](#)
7. [Flux](#) · [AssemblyAI](#) · [Soniox](#) · [Cartesia](#) · [OpenAI VAD](#)
8. [Krisp TP/IP](#) · [TEN](#) · [Easy Turn](#)
9. [Moshi](#) · [PersonaPlex](#) · [Endpoint Anticipation](#) · [GPT-Live](#)

Incertidumbres declaradas

- LiveKit v1 no publica backbone, training corpus, tamaño ni compute latency.
- El objetivo <25% FC @300 ms es una hipótesis razonada, no un resultado; se declara antes de correr y se reporta con bootstrap.
- Latencias de serving medidas en M4 con pesos de smoke test; el coste de forward no depende de los pesos pero sí de la CPU objetivo.
- Filas de OpenAI/AssemblyAI/Cartesia en EoT Bench leídas de una figura, no de una tabla. UltraVAD contradice 8B vs 0.7B.
- EoT Bench y TurnBench no son rankings intercambiables; las cifras owner-reported se presentan como tales.

Frase final

‘Entreno el baseline con la receta completa y sobre la decisión que realmente toma en producción; uso la señal que el benchmark permite y nadie usa; comparo en el harness público; y dejo una ruta clara hacia labels propios, ASR compartido, dual-channel y anticipación.’